Informe de avance del proyecto

Organizado por integrante, verificado contra el cronograma oficial

Corte al 29 de septiembre de 2026 — Fase 1 completa

Proyecto:
Evaluación comparativa de arquitecturas de Deep Learning frente a una línea base no paramétrica para la detección de anomalías en series de flujo vehicular en autopistas (PeMS-D4)

Asesor:
Dr. Esteban Tocto Cano

Universidad Peruana Unión
Facultad de Ingeniería y Arquitectura
Escuela Profesional de Ingeniería de Sistemas

Juliaca, septiembre de 2026

Índice

1. Estado frente al cronograma oficial **2**
1.1. Posición actual . . . 2
1.2. Nota sobre la desviación reportada previamente . . . 2

2. Wilbert Alex Mayta Arotaype (Código: 202212463) **2**
2.1. Tareas completadas . . . 2

3. Juan Enders Prieto Quispe (Código: 202210704) **3**
3.1. Tareas completadas . . . 3

4. Wrangler Choquechambi Luque (Código: 202220535) **3**
4.1. Tareas completadas . . . 3

5. Síntesis y siguiente acción **4**

1 Estado frente al cronograma oficial

1.1 Posición actual

Este informe se corta el **29 de septiembre de 2026**. Las tres semanas que componen la Fase 1 del cronograma – **Preparación de datos (7–27 de septiembre)** – están cerradas y verificadas en el entorno local del equipo.

Semana	Tareas	Estado	Verificación
1 (7–13 sep.)	Entorno, descarga, EDA inicial	Cerrada	En máquina local
2 (14–20 sep.)	Calidad de sensores, variables temporales, hora pico	Cerrada	En máquina local
3 (21–27 sep.)	Partición walk-forward, normalización, ventanas	Cerrada	En máquina local

1.2 Nota sobre la desviación reportada previamente

En el informe de corte anterior (22 de septiembre) se documentó un día de desviación sobre el cronograma: la Semana 3 debía iniciarse el lunes 21 y aún no se había tocado. Esa desviación quedó recuperada dentro de la misma semana — las tres tareas se completaron y verificaron antes del cierre del plazo, sin impacto en el punto de control (gate) programado para el 19–25 de octubre. Se deja esta nota en lugar de borrar el historial, siguiendo el mismo criterio de transparencia aplicado a las demás decisiones del proyecto.

2 Wilbert Alex Mayta Arotaype (Código: 202212463)

2.1 Tareas completadas

Descarga de PeMS-D4 y verificación de integridad (Semana 1)

Se descargó el archivo `pems04.npz` desde el repositorio de Song et al. (2020), verificándose su hash SHA-256 en tres momentos independientes:

`95a3c9b720fffdb85f0330d09bfab41b0b3cad0ca86c0d7d5f3accacb4ac999a`

resultado idéntico en las tres verificaciones, descartando corrupción o error de transferencia. Forma confirmada: $(16992, 307, 3)$.

Tratamiento de valores faltantes y calidad de sensores (Semana 2)

Se verificó la ausencia total de valores NaN e infinitos en el arreglo, reinterpretando el problema de "valores faltantes"del protocolo como un problema de calidad de sensor. Se diseñó y aplicó un criterio de exclusión doble (más de 20 % de observaciones en cero, o racha de flujo congelado de 24 horas o más), con sensibilidad documentada frente a un umbral alternativo de 2 horas (58 sensores excluidos, descartado por excesivo). Resultado aplicado: **16 de 307 sensores excluidos (5.2 %)**, verificado mediante control automático (`assert`) en la máquina local.

Variables temporales derivadas (Semana 2)

Se implementó la codificación cíclica de hora y día de la semana:

$$h_{sin} = \sin\left(\frac{2\pi h}{24}\right),\ h_{cos} = \cos\left(\frac{2\pi h}{24}\right),\ d_{sin} = \sin\left(\frac{2\pi d}{7}\right),\ d_{cos} = \cos\left(\frac{2\pi d}{7}\right)$$

evitando la discontinuidad artificial entre las 23:59 y las 00:00, y entre domingo y lunes.

Normalización z-score por pliegue (Semana 3)

Se aplicó $z = (x - \mu_{train})/\sigma_{train}$, con parámetros estimados exclusivamente con el rango de entrenamiento de cada pliegue. Las medias de flujo resultantes (209.97 / 210.40 / 211.83 para los pliegues 1, 2 y 3) aumentan de forma progresiva, confirmando — mediante control automático por `assert` — que cada pliegue usa su propio rango de entrenamiento y no el dataset completo.

3 Juan Enders Prieto Quispe (Código: 202210704)

3.1 Tareas completadas

Análisis exploratorio inicial (Semana 1)

Se calcularon estadísticas globales por variable:

Variable	Rango	Media	Mediana
Flujo	0 – 919	211.7	180
Ocupación	0 – 0.7716	0.053	0.044
Velocidad	3 – 85.2	63.5	65.6

y se verificó coherencia física: correlación flujo–ocupación de +0,615 y flujo–velocidad de −0,332, ambas con el signo físicamente esperado.

Regla de hora pico (Semana 2)

Se definió mediante evidencia empírica propia (percentil 75 del perfil horario promedio, agregando los 291 sensores retenidos), resultando en el conjunto $\{12, 13, 14, 15, 16, 17\}$ como horas pico. La regla se respaldó adicionalmente con el criterio de percentiles del *Highway Capacity Manual* para la definición de hora de diseño, y se documentó como limitación reconocida que el perfil resultante es una meseta y no el patrón bimodal clásico, atribuible a la mezcla de sensores de ambos sentidos de circulación en el promedio agregado.

Construcción de ventanas temporales (Semana 3)

Se implementó una función reutilizable de ventaneo (`src/ventanas.py`), en lugar de materializar y guardar las ventanas completas de los 3 pliegues (varios GB para modelos que aún no existen). Verificada sobre el Pliegue 1: 985 617 ventanas de entrenamiento y 988 818 de validación, con cuatro controles automáticos superados (conteo exacto, ausencia de NaN/Inf, coincidencia con corte manual, y rango correcto de instantes en validación).

4 Wrangler Choquechambi Luque (Código: 202220535)

4.1 Tareas completadas

Configuración del entorno de trabajo (Semana 1)

Se configuró el entorno de desarrollo (Python, entorno virtual, TensorFlow/Keras y dependencias asociadas vía `requirements.txt`), con control de versiones inicializado, sobre el cual se ejecutaron sin incidentes todos los scripts de las Semanas 1 y 2.

Partición temporal walk-forward (Semana 3)

Último 20 % cronológico (índices [13593, 16992), 17–28 feb. 2018) reservado como conjunto de prueba final. El 80 % restante dividido en 3 pliegues expansivos. Verificado mediante `assert`: ningún pliegue traslapa su entrenamiento con su validación, y ninguno toca el conjunto de prueba final.

5 Síntesis y siguiente acción

Las **9 tareas de las Semanas 1 a 3 están cerradas y verificadas** en el entorno local del equipo, cada una respaldada por evidencia documental (hashes, estadísticas, controles automáticos por `assert`) suficiente para sustentar ante el asesor o un jurado. Con esto, la **Fase 1 (Preparación de datos) queda completa**.

Siguiente acción recomendada: iniciar la Semana 4 (28 sep. – 4 oct.), Fase 2 del cronograma — Etiquetado mediante dos esquemas independientes. Prieto define el Esquema A (proxy estadístico por desviación); Choquechambi define el Esquema B (inyección controlada de anomalías puntuales, contextuales y colectivas, prevalencia 3 %).