Semana 1 — Preparación de datos

Informe de cierre organizado por integrante

(7 – 13 de septiembre de 2026)

Proyecto:
Evaluación comparativa de arquitecturas de Deep Learning frente a una línea base no paramétrica para la detección de anomalías en series de flujo vehicular en autopistas (PeMS-D4)

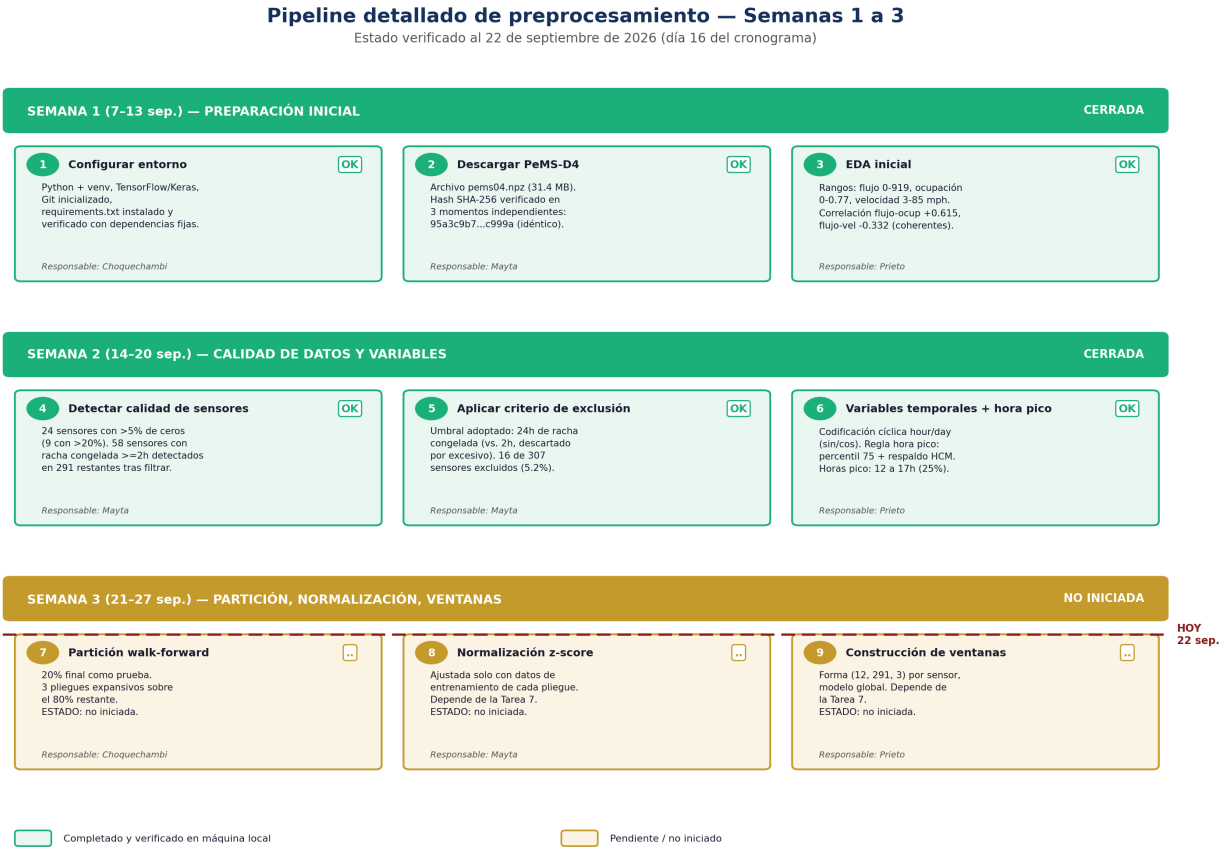
Asesor:
Dr. Esteban Tocto Cano

Universidad Peruana Unión
Facultad de Ingeniería y Arquitectura
Escuela Profesional de Ingeniería de Sistemas

Juliaca, septiembre de 2026

1 Diagrama de estado del pipeline

La siguiente figura muestra el pipeline completo de preprocesamiento (Semanas 1 a 3), con el estado real de cada paso verificado al 22 de septiembre de 2026. Los tres primeros pasos, correspondientes a esta semana, están completados y verificados.



2 Wilbert Alex Mayta Arotaype (Código: 202212463)

Tarea: Descarga de PeMS-D4 y verificación de integridad

Se descargó el archivo `pems04.npz` desde el repositorio de Song et al. (2020), verificándose su hash SHA-256 en tres momentos independientes:

`95a3c9b720fffdb85f0330d09bfab41b0b3cad0ca86c0d7d5f3accacb4ac999a`

resultado idéntico en las tres verificaciones. Forma confirmada: $(16992, 307, 3)$, coincidente con lo especificado en el Cuadro 4 del protocolo.

Justificación de la fuente: se optó por esta fuente en lugar de una recolección propia porque es el mismo estándar que usa la totalidad de los antecedentes revisados (garantiza comparabilidad), proviene de sensores físicos reales, su tamaño es estadísticamente suficiente para las pruebas planificadas, y es reproducible mediante verificación de hash.

3 Juan Enders Prieto Quispe (Código: 202210704)

Tarea: Análisis exploratorio inicial

Se calcularon estadísticas globales por variable:

Variable	Rango	Media	Mediana
Flujo	0 – 919	211.7	180
Ocupación	0 – 0.7716	0.053	0.044
Velocidad	3 – 85.2	63.5	65.6

Verificación de coherencia física: correlación flujo–ocupación de +0,615 y flujo–velocidad de −0,332, ambas con el signo físicamente esperado (más vehículos implica mayor ocupación; mayor flujo se asocia a velocidad moderadamente menor por congestión). Este control descarta que el archivo contenga datos corruptos o incoherentes antes de invertir tiempo en el resto del pipeline.

4 Wrangler Choquechambi Luque (Código: 202220535)

Tarea: Configuración del entorno de trabajo

Se configuró el entorno de desarrollo: Python con entorno virtual aislado, TensorFlow/Keras y dependencias asociadas instaladas vía `requirements.txt` versionado, y repositorio Git inicializado para control de cambios. Este entorno sirvió de base para ejecutar, sin incidentes de compatibilidad, todos los scripts de las Semanas 1 y 2.

5 Conclusión de la semana

Las tres tareas quedan cerradas con evidencia verificable y reproducible: cadena de custodia del dataset confirmada por hash, coherencia física de los datos confirmada mediante correlaciones, y entorno de trabajo estable y documentado. El proyecto queda en condiciones de avanzar a la Semana 2 sin deuda técnica pendiente de esta fase.