# Semana 2 — Calidad de datos y variables temporales

Informe de cierre organizado por integrante

(14 – 20 de septiembre de 2026)

**Proyecto:**
Evaluación comparativa de arquitecturas de Deep Learning frente a una línea base no paramétrica para la detección de anomalías en series de flujo vehicular en autopistas (PeMS-D4)

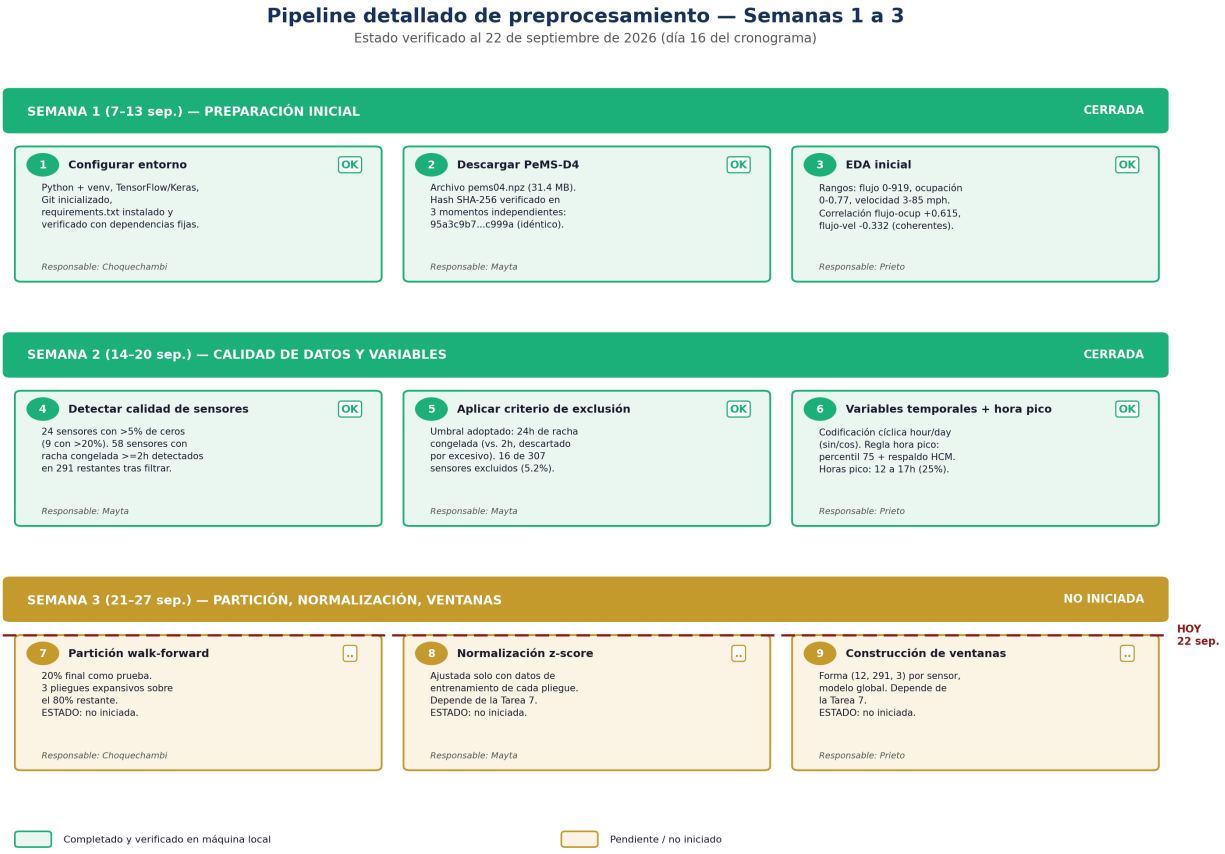
**Asesor:**
Dr. Esteban Tocto Cano

Universidad Peruana Unión
Facultad de Ingeniería y Arquitectura
Escuela Profesional de Ingeniería de Sistemas

Juliaca, septiembre de 2026

# 1 Diagrama de estado del pipeline

Los pasos 4, 5 y 6 de la figura, correspondientes a esta semana, están completados y verificados. Los pasos 7 a 9 (Semana 3) se muestran como referencia del trabajo inmediato siguiente, aún no iniciado a la fecha de corte.




# 2 Wilbert Alex Mayta Arotaype (Código: 202212463)

## Tarea: Detección y exclusión de sensores de baja calidad

Se verificó la ausencia total de valores NaN e infinitos en el arreglo (`np.isnan().sum() == 0`), reinterpretando el requisito de ïnterpolación de valores faltantes"del protocolo como un problema de **calidad de sensor**, no de huecos NaN.

Se detectaron dos patrones de falla: 24 sensores con más de 5 % de observaciones en cero (9 de ellos con más de 20 %), y 58 sensores con al menos una racha de 2 horas o más de flujo exactamente congelado.

**Decisión de umbral:** se evaluó un umbral de 2h (excluiría 58 sensores, 18.9 % del dataset — excesivo, dado que gran parte puede ser tráfico real de madrugada) frente a un umbral de 24h (aísla los casos sin otra explicación razonable que falla de sensor). Se adoptó el criterio de 24h.

**Resultado, verificado en máquina local:** 16 de 307 sensores excluidos (5.2 %), mediante control automático (`assert`) que detiene la ejecución si el conteo no coincide con lo documentado. Sin traslape entre los dos criterios de exclusión aplicados.

**Por qué exclusión y no interpolación:** interpolar una racha de 24 horas o más equivaldría a generar sintéticamente casi un día completo de tráfico dentro de una serie que se presenta como real, contradiciendo el propósito del estudio.

### Tarea: Variables temporales derivadas

Codificación cíclica de hora y día de la semana:

$$h_{sin} = \sin\left(\frac{2\pi h}{24}\right),\ h_{cos} = \cos\left(\frac{2\pi h}{24}\right),\ d_{sin} = \sin\left(\frac{2\pi d}{7}\right),\ d_{cos} = \cos\left(\frac{2\pi d}{7}\right)$$

Evita la discontinuidad artificial entre las 23:59 y las 00:00, y entre domingo y lunes.

## 3 Juan Enders Prieto Quispe (Código: 202210704)

### Tarea: Definición y documentación de la regla de hora pico

**Enfoque empírico:** se calculó el perfil horario promedio de flujo agregando los 291 sensores retenidos, definiendo como hora pico toda hora que supere el percentil 75 del perfil de 24 horas (umbral: 292.3). Resultado: horas $\{12, 13, 14, 15, 16, 17\}$.

**Respaldo en literatura:** el *Highway Capacity Manual* define la hora pico mediante percentiles de la distribución observada de volúmenes (concepto de hora de diseño), no mediante un rango fijo de reloj — el mismo principio aplicado aquí, lo que posiciona la regla como coherente con la práctica estándar de la disciplina.

**Limitación reconocida:** el perfil resultante es una meseta de mediodía-tarde, no el patrón bimodal clásico mañana/tarde, probablemente porque el promedio agregado mezcla sensores de ambos sentidos de circulación. Se documenta explícitamente en lugar de omitirse.

**Resultado aplicado:** 4 248 de 16 992 pasos marcados como hora pico (25.0 %, consistente por construcción con 6 de 24 horas).

## 4 Wrangler Choquechambi Luque (Código: 202220535)

Sin tareas asignadas en el cronograma para la Semana 2. Su siguiente tarea (partición temporal walk-forward) corresponde a la Semana 3, actualmente pendiente de inicio — ver Sección 1.

## 5 Conclusión de la semana

Las tres tareas de la Semana 2 quedan cerradas con evidencia verificable y ejecutada en el entorno local del equipo. La ausencia de valores NaN se documentó y reinterpretó correctamente como un problema de calidad de sensor, resuelto mediante un criterio de exclusión explícito y sensible al umbral elegido. Las variables temporales siguen exactamente la especificación del protocolo, y la regla de hora pico cuenta con doble respaldo (empírico y literatura), con su limitación declarada. El proyecto queda listo para la Semana 3, cuya tarea inicial (partición walk-forward, Choquechambi) es la dependencia directa de las otras dos tareas de esa semana.