# Justificación del dataset, confidencialidad y verificación de integridad

PeMS-D4 — Detección de anomalías en flujo vehicular en autopistas

**Proyecto:**
Evaluación comparativa de arquitecturas de Deep Learning frente a una línea base no paramétrica para la detección de anomalías en series de flujo vehicular en autopistas (PeMS-D4)

**Elaborado por:**
Mayta Arotaype, Wilbert Alex (Código: 202212463)
Prieto Quispe, Juan Enders (Código: 202210704)
Choquechambi Luque, Wrangler (Código: 202220535)

**Asesor:**
Dr. Esteban Tocto Cano

Universidad Peruana Unión
Facultad de Ingeniería y Arquitectura
Escuela Profesional de Ingeniería de Sistemas

Juliaca, septiembre de 2026

## 1 Justificación de la fuente de datos

El dataset PeMS-D4 utilizado en este proyecto corresponde al publicado originalmente por Song, Lin, Guo y Wan (2020), en el marco del trabajo *Spatial-Temporal Synchronous Graph Convolutional Networks* (STSGCN, AAAI 2020), construido a partir de mediciones reales del sistema Caltrans Performance Measurement System (PeMS). Se optó por esta fuente, y no por una recolección propia de datos en tiempo real, por las siguientes razones:

1. **Comparabilidad con la literatura revisada.** La totalidad de los antecedentes analizados en la revisión de estado del arte del proyecto evalúan sus arquitecturas sobre datasets fijos y públicos de la familia PeMS, no sobre datos en vivo. Usar el mismo estándar permite que los resultados de este estudio sean comparables con los reportados en la literatura.

2. **Validez de datos reales de campo.** A diferencia de datasets sintéticos, PeMS-D4 proviene de sensores físicos de inducción instalados en autopistas reales del Área de la Bahía de San Francisco, lo que preserva la variabilidad, el ruido y la estacionalidad genuinos del flujo vehicular.

3. **Tamaño estadísticamente suficiente.** Con 307 sensores y tres pliegues temporales, el diseño produce bloques sensor × pliegue en cantidad suficiente para sostener la prueba de Friedman y los contrastes post-hoc planificados en la metodología.

4. **Reproducibilidad verificable.** El archivo es de acceso público, no requiere registro ni autorización especial, y su integridad puede verificarse mediante hash criptográfico (ver Sección 3), cumpliendo el estándar de reproducibilidad exigido por el protocolo.

El acceso directo desde el repositorio del autor original de STSGCN (`https://github.com/Davidham3/STSGCN`) se realiza mediante un enlace de almacenamiento en la nube (Baidu Netdisk) sin acceso directo por URL desde fuera de China. Por ello, el archivo se obtuvo de su repositorio complementario, de acceso público y descarga directa:

`https://github.com/Davidham3/ASTGCN/blob/master/data/PEMS04/pems04.npz`

Esta ruta de acceso está respaldada por su uso explícito en la literatura revisada por pares: al menos un estudio publicado en *PLOS ONE* (2025) declara esta misma URL como fuente de datos en su sección de disponibilidad de datos (*Data Availability Statement*), lo que confirma que es una fuente académicamente aceptada y no una redistribución no verificada.

## 2 Confidencialidad y aspectos éticos

PeMS-D4 no contiene datos personales ni información que permita identificar a personas. Las variables registradas —flujo vehicular, ocupación y velocidad promedio— son mediciones agregadas por estación de sensor y por intervalo de cinco minutos, obtenidas mediante detectores de inducción instalados en la vía. El sistema **no registra matrículas, identidad de conductores, ni trayectorias de vehículos individuales**; a diferencia de datasets de taxis o viajes por aplicativo utilizados en otros estudios del área (por ejemplo, NYC Taxi o Uber Nashville), no existe riesgo de reidentificación de personas a partir de esta información.

En consecuencia, el uso de este dataset no requiere consentimiento informado individual ni aprobación de un comité de ética en investigación con seres humanos, dado que no involucra participantes humanos ni datos personales identificables.

**Sobre los términos de uso:** no se identificó un archivo de licencia explícito (`LICENSE`) en el repositorio de redistribución utilizado. Dado que el dato subyacente proviene de un sistema

público operado por una entidad gubernamental (Caltrans) y que su uso académico está ampliamente precedentado en la literatura revisada por pares citada en la Sección 1, se considera un uso legítimo con fines de investigación no comercial. Se declara esto explícitamente para evitar cualquier afirmación de licencia que no pueda respaldarse con una fuente verificada.

## 3 Verificación de integridad (hash)

Para garantizar que el archivo utilizado no ha sido alterado ni corrompido durante la descarga, se calculó su huella digital mediante el algoritmo SHA-256:

`95a3c9b720fffdb85f0330d09bfab41b0b3cad0ca86c0d7d5f3accacb4ac999a`

Este valor fue calculado de forma independiente en dos entornos distintos (verificación cruzada) el 15 de septiembre de 2026, obteniendo un resultado idéntico en ambos casos, lo que confirma la integridad del archivo.

**Cómo calcular este hash de forma independiente**, para verificarlo en cualquier momento:

- **Windows (cmd):** `certutil -hashfile pems04.npz SHA256`
- **Windows (PowerShell):** `Get-FileHash pems04.npz -Algorithm SHA256`
- **Linux / Mac:** `sha256sum pems04.npz`

Si el resultado no coincide exactamente con el valor documentado arriba, el archivo fue alterado o la descarga se corrompió, y debe descargarse nuevamente antes de continuar con el preprocesamiento.

## 4 Estructura del archivo y modo de uso

El archivo es un arreglo de NumPy comprimido (`.npz`) de 31.4 MB, con una sola clave interna, `data`, de forma `(16992, 307, 3)`: 16 992 pasos temporales (cada uno de 5 minutos, del 1 de enero al 28 de febrero de 2018), 307 sensores, y 3 variables en este orden: flujo, ocupación, velocidad.

| Atributo | Valor |
|---|---|
| Forma del arreglo | (16992, 307, 3) |
| Tipo de dato | float64 |
| Valores NaN / infinitos | 0 (ninguno) |
| Valores negativos | 0 (ninguno) |
| Rango de flujo | 0 – 919 |
| Rango de ocupación | 0 – 0.7716 |
| Rango de velocidad | 3 – 85.2 |
| Correlación flujo–ocupación | +0.615 |
| Correlación flujo–velocidad | –0.332 |

Se carga en Python de la siguiente forma:

```
import numpy as np
d = np.load("pems04.npz")
raw = d["data"]           # forma (16992, 307, 3)
flujo = raw[:, :, 0]       # (16992, 307)
ocupacion = raw[:, :, 1]   # (16992, 307)
velocidad = raw[:, :, 2]   # (16992, 307)
```

El archivo no incluye una columna de *timestamps* explícita: el índice temporal debe construirse asumiendo un paso de 5 minutos desde el 1 de enero de 2018, 00:00 horas:

```
import pandas as pd
timestamps = pd.date_range(start="2018-01-01 00:00",
                           periods=16992, freq="5min")
```

## 5 Referencia bibliográfica

Song, C., Lin, Y., Guo, S., & Wan, H. (2020). Spatial-temporal synchronous graph convolutional networks: A new framework for spatial-temporal network data forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(01), 914–921.