Aprendizaje profundo frente a una línea base no paramétrica para la detección de anomalías en el flujo vehicular de autopistas: protocolo uniforme y diseño de sensibilidad al etiquetado en PeMS-D4

Wilbert Alex Mayta Arotaype
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión
Juliaca, Perú
correo o ORCID

Juan Enders Prieto Quispe
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión
Juliaca, Perú
correo o ORCID

Wrangler Choquechambi Luque
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión
Juliaca, Perú
correo o ORCID

Esteban Tocto Cano
Escuela Profesional de Ingeniería de Sistemas
Universidad Peruana Unión
Juliaca, Perú
correo o ORCID

***Resumen*—Los detectores de anomalías de tráfico basados en aprendizaje profundo suelen reportarse con conjuntos de datos, particiones, umbrales y etiquetas heterogéneos, mientras que estudios recientes muestran que los detectores estadísticos simples suelen ser competitivos una vez eliminados los defectos de evaluación. Presentamos un protocolo uniforme, cuyas reglas principales se fijaron antes de ver cualquier resultado de redes neuronales, que compara seis familias de aprendizaje profundo (LSTM, GRU, CNN-1D, autoencoder, Transformer e híbrido CNN-LSTM-GRU) y un modelo publicado (SI-DMSeq) frente a una línea base no paramétrica de estadísticos móviles sobre series de flujo de autopistas de PeMS-D4. El protocolo usa validación temporal progresiva, un procedimiento común y reducido de ajuste para las seis familias entrenadas (el modelo publicado queda en su configuración por defecto), tres semillas para los modelos finales, PR-AUC sin ajuste por puntos, pruebas pareadas con corrección de Holm, medición de latencia y dos esquemas de etiquetado construidos por separado: un proxy estadístico causal y la inyección controlada de anomalías puntuales, contextuales y colectivas, para evaluar si el ranking de detectores depende de cómo se definen las anomalías. Los resultados preliminares, que pasaron las verificaciones automáticas de consistencia especificadas, abarcan la depuración de datos (291 de 307 sensores conservados), ambos esquemas de etiquetado y la línea base. El esquema proxy produce una prevalencia de 0.10 por ciento y solo 29.2 por ciento de los bloques de evaluación contiene ambas clases; su conjunto positivo casi no se solapa con el inyectado (índice de Jaccard de a lo sumo 0.0012); y la línea base alcanza un PR-AUC medio por bloque de 0.345 en prueba bajo inyección, unas 11 veces el azar, pero un PR-AUC agregado de solo 0.003 bajo el proxy, unas tres veces el azar. Los tiempos de entrenamiento medidos obligaron a una búsqueda de hiperparámetros reducida y declarada de antemano. Los resultados de aprendizaje profundo y las pruebas estadísticas están pendientes.**

***Index Terms*—detección de anomalías, aprendizaje profundo, protocolo de evaluación, PeMS, series temporales, flujo vehicular, inyección sintética de anomalías**

I. Introducción

Contexto y afectados. Los centros de gestión de tráfico, como el Departamento de Transporte de California (Caltrans), que patrocina PeMS [1], dependen de sensores de autopista para detectar perturbaciones, y los conductores sufren las demoras. La Administración Federal de Carreteras de EE. UU. atribuye cerca de la mitad de la congestión a perturbaciones temporales, y solo los incidentes explican 25 % de la congestión [2]. En el área de la Bahía de San Francisco, INRIX estimó que la congestión costó a cada conductor 79 horas y USD 2 250 en 2017, el año previo al periodo estudiado aquí [3]. Detectar a tiempo observaciones atípicas tiene por tanto valor operativo. Si los detectores se adoptan por resultados que no se pueden comparar, un operador puede pagar modelos profundos costosos sin una ventaja demostrada sobre una regla simple, y por eso hace falta un protocolo uniforme de evaluación.

Los detectores de lazo en autopistas producen series de flujo densas, estacionales y ruidosas, en las que identificar a tiempo observaciones atípicas apoya el monitoreo del tráfico. Se han propuesto detectores de aprendizaje profundo (DL) basados en recurrencia, convolución, reconstrucción o atención [4]–[7], pero sus resultados son difíciles de comparar: los estudios difieren en datos, particiones, etiquetas, umbrales y métricas, y los grandes conjuntos públicos de autopistas como PeMS se construyeron para pronóstico y no traen etiquetas de anomalía [8]. Por ello las etiquetas se derivan de bitácoras de incidentes, reglas o simulación [9], [10], y una anomalía estadística no es necesariamente un incidente real.

Dos líneas de evidencia motivan una evaluación más estricta. El ajuste por puntos (PA) infla tanto los puntajes que puntajes aleatorios alcanzan F1 de estado del arte [11], y los benchmarks populares son en gran parte resolubles con reglas de una línea basadas en estadísticos móviles [12]. Cuando la evaluación es controlada, los detectores clásicos igualan o superan a los profundos en benchmarks genéricos [13]–[16] y en volumen de tráfico etiquetado por expertos [17]; además, la calidad de las etiquetas cambia las conclusiones en la detección de incidentes viales [9], y los rankings varían con el tipo de anomalía y la métrica [16], [18].

Objeto de investigación y problema. El objeto de estudio es la detección de anomalías en el flujo vehicular de autopistas con aprendizaje profundo, analizada en PeMS-D4 con el bloque detector × esquema de etiquetado × sensor-pliegue como unidad de análisis. El problema es si los detectores DL ofrecen una ventaja reproducible sobre una línea base de estadísticos móviles, y si el ranking resultante se mantiene estable ante distintas definiciones operativas de anomalía y bajo una restricción de costo de inferencia.

Vacío de conocimiento. Ya existen comparaciones uniformes para series genéricas [13], [16] y para volumen de tráfico urbano [17]. Lo que no se sabe es si la posición relativa de los detectores DL frente a una línea base simple en flujo de autopistas sobrevive a un cambio en la forma de definir las anomalías. En la literatura revisada, ningún estudio examina esto sobre una misma partición temporal de un conjunto de autopistas y a la vez compara familias DL genéricas, una línea base no paramétrica y un modelo de tráfico publicado, trata la latencia de inferencia como criterio de primer orden y cuantifica la variabilidad entre semillas con control de comparaciones múltiples (Tabla I). El vacío es por tanto de evidencia sobre robustez, no de detectores.

Objetivos y preguntas. *Objetivo general:* determinar si los detectores DL ofrecen una ventaja reproducible sobre una línea base de estadísticos móviles (G0) en PeMS-D4 y si el ranking de detectores es estable entre esquemas de etiquetado. *Objetivos específicos:* (O1) estimar, bajo el Esquema B, la diferencia de PR-AUC entre cada detector DL y G0; (O2) establecer cuáles de los detectores que superan a G0 cumplen un criterio de latencia predefinido; (O3) cuantificar la concordancia entre los rankings de detectores bajo los Esquemas A y B. *Preguntas de investigación:* RQ1 (O1, H1), ¿cuánto mejora, si es que lo hace, algún detector DL la precisión promedio de G0 bajo el Esquema B; RQ2 (O2, H2), ¿cumplen el criterio de latencia los detectores que mejoran a G0; RQ3 (O3, H3), ¿es estable el ranking de detectores entre esquemas de etiquetado? Análisis con entradas controladas y por tipo de anomalía prueban la robustez de estas comparaciones.

Aportes declarados. (1) *Empírico:* evidencia sobre si la posición de los detectores DL frente a una línea base móvil en flujo de autopistas es robusta a la definición de anomalía (resultados DL pendientes); (2) *metodológico:* un protocolo reproducible para PeMS-D4 que operacionaliza prácticas destiladas de los estudios semilla, con dos esquemas de etiquetado construidos por separado y un criterio a priori de estabilidad del ranking; (3) *práctico:* la latencia como criterio explícito, con un frente de Pareto PR-AUC×latencia. Los resultados preliminares aquí reportados conciernen solo a los datos, las etiquetas y la línea base.

Cuadro I
CARACTERÍSTICAS DE PROTOCOLO REPORTADAS POR LOS ESTUDIOS SEMILLA. TR: DATOS DE TRÁFICO; NB: LÍNEA BASE NO PROFUNDA; CS: PARTICIÓN CRONOLÓGICA DECLARADA; NT: SIN PA NI UMBRAL AJUSTADO EN PRUEBA PARA LA MÉTRICA PRINCIPAL; RR: CORRIDAS REPETIDAS; ST: PRUEBA DE SIGNIFICANCIA; LT: TIEMPO/LATENCIA. ✓ SÍ, ✗ NO, P PARCIAL, N.I. NO INFORMADO, – NO APLICA, PLAN: PLANIFICADO, AÚN NO EJECUTADO.

Estudio	Tr	NB	CS	NT	RR	ST	LT
Taheri'26 [17]	✓	✓	n.i.	✗	n.i.	✗	✗
Taheri'24 [22]	✓	✓	n.i.	✗	✓	✗	✗
FT-AED'24 [8]	✓	p	n.i.	✓	✗	✗	✗
Sun'22 [9]	✓	✗	✓	✓	✓	✗	✗
Zhang'22 [4]	✓	✓	n.i.	✓	✗	✗	✗
Ijaradar'25 [6]	✓	✓	n.i.	n.i.	n.i.	✗	✗
Nouri'25 [7]	✓	✗	✓	–	✗	✗	✓
Kim'22 [11]	✗	✓	–	✗	p	✗	✗
Audibert'22 [14]	✗	✓	–	✗	n.i.	✓	✗
Schmidl'22 [13]	✗	✓	–	✓	n.i.	✗	✓
Liu'24 [16]	✗	✓	–	✓	✗	✓	n.i.
Este protocolo	✓	✓	✓	✓	*plan*	*plan*	*plan*

II. TRABAJOS RELACIONADOS Y PRÁCTICAS DESTILADAS

Detección de anomalías de tráfico. Los detectores reportados incluyen pronóstico con atención sobre grafos [4], autoencoders CNN y BiLSTM [5], un autoencoder GCN-LSTM-atención evaluado con anomalías artificiales [6] y SI-DMSeq, un codificador–decodificador LSTM multitarea que marca perturbaciones con una carta de control [7]. El etiquetado es el principal obstáculo: la supervisión débil elevó el F1 de la clase incidente de un LSTM de 0.69 a 0.88 en el Distrito 4 de PeMS [9], y FT-AED combina registros de choques con etiquetas de expertos [8]. En datos de volumen etiquetados por expertos, un perfil horario media$\pm c\cdot$desv. alcanzó F1 0.566 frente a 0.120 de un LSTM [17].

Defectos de evaluación. Con PA, puntajes uniformemente aleatorios alcanzan F1 0.969 en SWaT frente a 0.216 sin él [11]; 316 de 367 series de Yahoo son separables con una línea de media/desviación móviles [12]. El AUC-ROC está dominado por los verdaderos negativos bajo desbalance [16], [18], pero el PR-AUC puntual no es robusto a pequeños desfases temporales [16].

Etiquetas sintéticas. Las anomalías se dividen en puntuales (globales, contextuales) y por patrón [19]. Las anomalías inyectadas ayudan a entrenar y seleccionar detectores, pero difieren de las reales y solo transfieren cuando coinciden los tipos [20], [21].

La Tabla I resume las características de protocolo reportadas por los estudios semilla y motiva cada decisión de diseño de la Sección III.

III. PROTOCOLO

Diseño. Experimento computacional comparativo con estructura factorial (detector × esquema de etiquetado) y me-

didas repetidas sobre bloques sensor×pliegue, con validación temporal progresiva y un bloque de prueba reservado.

Datos. PeMS-D4 [23] contiene flujo, ocupación y velocidad de 307 sensores de autopista del área de la Bahía de San Francisco, del 1 ene al 28 feb 2018, con resolución de 5 min (16 992 pasos por sensor). Se excluyeron *a priori* los sensores con más de 20 % de ceros o una racha congelada de 24 h, quedando 291. Cada muestra es una ventana de 12 pasos ($t-11..t$, una hora) con $F=8$ entradas (flujo, ocupación, velocidad, codificaciones cíclicas de hora y día de la semana, y un indicador de hora pico); la etiqueta es la del paso final t, de modo que todos los métodos puntúan el mismo instante. Se entrena un modelo global por arquitectura con las ventanas de todos los sensores.

Partición. El último 20 % de cada serie es un bloque de prueba reservado que se usa una sola vez. El primer 80 % forma tres pliegues progresivos de validación temporal; la normalización z-score, los hiperparámetros y los umbrales se ajustan solo con las partes de entrenamiento y validación de cada pliegue, nunca con datos de prueba (Tabla I, CS/NT).

Esquemas de etiquetado. El *Esquema A* (proxy) etiqueta $x_{s,t}$ como anómalo cuando $|z_{s,t}|>3$, con media y desviación estándar calculadas causalmente sobre los 288 pasos previos de flujo crudo; la prevalencia anticipada era de 0.3–2 %. La línea base G0 pertenece a la misma familia de reglas (media y desviación móviles, aunque con una ventana mucho más corta), por lo que A se usa solo para la prueba de estabilidad del ranking (H3) y nunca para H1. El *Esquema B* inyecta anomalías puntuales, contextuales y colectivas (3, 6 o 12 pasos) en series reales, perturbando flujo, ocupación y velocidad, con 3 % de prevalencia objetivo por partición y por bloque sensor× pliegue, semilla de inyección fija, restricciones físicas (flujo y velocidad ≥ 0; ocupación en $[0,1]$) y sin solapamiento entre particiones. Las anomalías contextuales reemplazan un valor por uno menor al percentil 5 o mayor al 95 de un perfil hora×día de la semana por sensor, estimado con datos de entrenamiento, una familia de reglas distinta de G0 [19].

Condiciones. G0: detector móvil no paramétrico solo sobre flujo; puntúa cada paso con el z-score absoluto sobre los w pasos previos (ventana $w\in\{6,11,22,44\}$ pasos y multiplicador de umbral $k\in\{2.0,2.5,3.0\}$, una grilla de 12 puntos). G1: LSTM; G2: GRU; G3: CNN-1D; G4: autoencoder (error de reconstrucción como puntaje); G5: encoder Transformer; G6: híbrido CNN-LSTM-GRU; G7: SI-DMSeq [7] con su configuración publicada, usando el error de reconstrucción local de la serie en el paso t como puntaje puntual. G1–G3, G5 y G6 optimizan una pérdida supervisada de clasificación (salida sigmoide, entropía cruzada binaria). G4 optimiza una pérdida de reconstrucción sobre ventanas cuya etiqueta del paso final es normal bajo el esquema correspondiente, por lo que esas ventanas pueden contener pasos anómalos anteriores. G0 y G7 no optimizan ninguna pérdida supervisada de clasificación, aunque se usa selección basada en etiquetas donde se especifica (ventana y umbral de G0 en validación). Arquitectura y grado de uso de etiquetas están por tanto parcialmente confundidos, y la comparación es entre sistemas detectores y no entre arquitecturas aisladas. G0–G6 se implementan en TensorFlow/Keras. Cada una de G1–G6 evalúa 12 configuraciones por esquema, la primera es su especificación inicial y las otras 11 se sortean de los rangos fijos de la Tabla II con semilla determinista. G7 se mantiene en PyTorch y sin ajuste, una asimetría declarada a priori.

Cuadro II
ESPACIO DE BÚSQUEDA DE G1–G6. EL PRIMER VALOR DE CADA LISTA ES LA ESPECIFICACIÓN INICIAL (CONFIGURACIÓN 0); LAS OTRAS 11 CONFIGURACIONES SE SORTEAN DE ESTAS LISTAS.

Modelo	Valores
G1 LSTM, G2 GRU	unidades $\{[64,32],[32,16],[128,64]\}$; dropout $\{0.1,0.2,0.3\}$; tasa de aprendizaje $\{5\times10^{-4},10^{-3},2\times10^{-3}\}$
G3 CNN-1D	filtros $\{[32,64,128],[16,32,64],[64,128,256]\}$; kernel $\{3,5\}$; decaimiento de pesos $\{10^{-4},0,10^{-3}\}$; tasa como G1
G4 autoencoder	capas $\{[32,16,8],[64,32,16],[32,16,4]\}$; L2 $\{0,10^{-5},10^{-4}\}$; tasa como G1
G5 Transformer	bloques $\{2,1,3\}$; cabezas 4; d_{model} $\{64,32\}$; feed-forward $\{128,64\}$; dropout $\{0.1,0.2\}$; tasa $\{5\times10^{-4},3\times10^{-4},10^{-3}\}$; decaimiento $\{10^{-4},10^{-3}\}$
G6 CNN-LSTM-GRU	filtros $\{64,32\}$; kernel $\{3,5\}$; unidades LSTM $\{64,32\}$; unidades GRU $\{32,16\}$; dropout $\{0.2,0.1,0.3\}$; tasa como G1

Búsqueda reducida. La búsqueda nominal (6 arquitecturas × 2 esquemas × 3 pliegues × 12 configuraciones × 3 semillas) son 1 296 entrenamientos; con los 4.3–5.4 min por época medidos en el pliegue 3 (CPU, LSTM), 30 épocas cada uno superan 70 días. Antes de cualquier búsqueda fijamos una reducción para todas las arquitecturas: una semilla, como máximo 10 épocas con parada temprana (paciencia 3) sobre PR-AUC, una de cada cuatro ventanas de entrenamiento y selección sobre el bloque de validación *completo*. La ganadora se reentrena con todo el bloque de 80 %, tres semillas, todas las ventanas y sin parada temprana, usando la mediana de la mejor época. El costo se cronometró en un AMD Ryzen 7 7445HS (6 núcleos, 12 hilos) con 15.2 GB de RAM, en CPU (TensorFlow 2.16.2); una corrida en GPU (RTX 4050, bajo WSL2) fue más lenta para este modelo y tamaño de lote (unos 12 frente a 5.4 min por época). Cada corrida registra su hardware y los tiempos de entrenamiento se comparan entre arquitecturas solo si se midieron en la misma máquina.

Selección y métricas. Se elige la configuración que maximiza el PR-AUC medio de validación sobre los tres pliegues; el umbral de F1 y el umbral que alcanza recall 0.90 se eligen en el último bloque de validación (los modelos finales se reentrenan con ese bloque, lo que puede sesgar F1 y FPR pero no el PR-AUC). La métrica primaria es el PR-AUC (precisión promedio, AP), cuyo nivel de azar es la prevalencia. El AP medio por bloque es la media simple del AP por sensor sobre los bloques evaluables; el AP agregado se calcula sobre puntajes y etiquetas concatenados de todos los pasos válidos de una partición y se reporta con su prevalencia. El PR-AUC de G0 depende solo de w; k fija el umbral binario usado para F1. F1, AUC-ROC y la tasa de falsos positivos (FPR) en el umbral

de F1 y en el umbral de recall 0.90 son secundarios, y el recall realmente alcanzado en prueba se reporta junto con esa FPR; el PA está prohibido [11], [18]. Como las anomalías colectivas dominan los instantes inyectados, el AP se reporta también por tipo de anomalía, tomando como positivos los instantes de un tipo y como negativos los instantes normales (los otros tipos se excluyen). La latencia se mide con `perf_counter` tras 100 llamadas de calentamiento sobre $\geq$1000 llamadas, con lote 1 y una ventana por sensor, reportando mediana, p95 e IC 95 %; el criterio operativo es $\leq$10 ms por ventana, complementado con el frente de Pareto PR-AUC$\times$latencia.

Controles contra un atajo de firma. Las redes ven ocho canales, G0 solo el flujo, y el Esquema B perturba varios canales, por lo que una red podría explotar la firma de la inyección en lugar de detectar mejor las anomalías de flujo. El AP por tipo y una ablación reentrenada con ocupación y velocidad en cero lo abordan; la ablación conserva los canales de hora, día de la semana y hora pico, por lo que la información sigue sin igualar a la de G0. El entrenamiento con pesos de clase prueba la sensibilidad al desbalance, no el atajo. Estos análisis se fijaron tras una corrida exploratoria mínima que no se reporta como resultado.

Hipótesis y estadística. H1: al menos un detector DL supera a G0 en PR-AUC medio por bloque en prueba bajo el Esquema B por al menos $\delta = 0.05$ de PR-AUC absoluto (cerca de 14 % del 0.345 de G0), un margen que descarta ganancias triviales y se fija antes de abrir el bloque de prueba (H0: ninguno lo hace). H2, condicionada a H1: al menos un detector que cumple H1 satisface el criterio de latencia (mediana de una ventana, lote 1, solo inferencia del modelo, CPU común; también se reporta p95); H0: ninguno. H3: el ranking de detectores no es estable entre esquemas (τ de Kendall < 0.7); H0: $\tau \geq 0.7$. Cada alternativa enuncia el efecto a demostrar (una ventaja, cumplir la latencia, un cambio de ranking), por lo que H3 se formula como inestabilidad. Los pliegues de validación sirven para selección y comparaciones exploratorias (prueba de Friedman sobre los 291×3 bloques, Nemenyi [24]); H1 se evalúa primordialmente sobre los 291 bloques de prueba reservados, después de congelar configuraciones, semillas, reglas de agregación y comparaciones, con pruebas pareadas frente a G0 y corrección de Holm ($\alpha = 0.05$). Sensores y pliegues progresivos no son independientes y Holm no corrige la dependencia, por lo que la significancia es indicativa y se reportan tamaños de efecto e intervalos. El AP por bloque se calcula por semilla y se promedia sobre las tres semillas antes de la prueba; también se reportan resultados por semilla. Los bloques sin alguna de las clases se excluyen y se reportan. Para H3 las condiciones se ordenan por PR-AUC medio por bloque en cada esquema (bloques válidos en ambos, remuestreados para un IC 95 % bootstrap de τ): el ranking es estable si todo el IC está en 0.7 o por encima, H3 se apoya si está por debajo, y el resultado es inconcluso en otro caso; la ρ de Spearman es un análisis de sensibilidad. Como H3 cambia a la vez etiquetas, prevalencia, ejemplos de entrenamiento, configuraciones seleccionadas y datos perturbados, evalúa la sensibilidad del procedimiento completo a la definición de anomalía, no solo de las etiquetas de evaluación. Bajo el Esquema A la ventaja sobre G0 se reporta solo de forma descriptiva, porque A comparte la familia de reglas de G0.

Cuadro III
EVIDENCIA OBTENIDA A LA FECHA FRENTE A ANÁLISIS PENDIENTES. EL NIVEL DE AZAR ES IGUAL A LA PREVALENCIA.

Ítem	Resultado
Obtenido	
Sensores conservados tras control de calidad	291 de 307 (16 excluidos, 5.2 %)
Prevalencia Esquema A	0.10 % (4 873 / 4 860 864); 0.086–0.125 % por partición
Prevalencia Esquema B	3.02–3.06 % por bloque
Composición Esquema B (instantes)	74.7 % colectiva, 14.6 % puntual, 10.7 % contextual
Solapamiento A vs. B (Jaccard)	0.0003–0.0012
Bloques con ambas clases	A: 340/1 164 (29.2 %); B: 100 %
Config. elegida de G0 (A y B)	ventana 22, multiplicador 3.0 (multiplicador en el borde de la grilla; no afecta el PR-AUC)
G0 prueba, Esquema B	PR-AUC medio por bloque 0.345 ($\approx$11.3$\times$ azar); agregado 0.335 (11.0$\times$); F1 0.323; AUC-ROC 0.792; FPR 54.3 % en el umbral que alcanza recall 0.90 en validación
G0 prueba, Esquema B, por tipo	puntual 0.905; contextual 0.399; colectiva 0.131
G0 prueba, Esquema A	PR-AUC medio por bloque 0.084 (84 de 291 bloques evaluables); agregado 0.003 (3.0$\times$); F1 0.021; FPR 65.6 % en el umbral de recall 0.90 derivado de validación
Pendiente	
Búsqueda y entrenamiento final G1–G6	*pendiente*
Friedman/Holm, Nemenyi (H1)	*pendiente*
Latencia, frente de Pareto (H2); prueba de humo G7	*pendiente*
τ de Kendall, ρ de Spearman (H3)	*pendiente*
Ablación de canales, pesos de clase	*pendiente*

IV. RESULTADOS PRELIMINARES

La Tabla III reporta la evidencia obtenida hasta ahora (semanas 1–8) y lo que sigue pendiente. El pipeline, ambos esquemas de etiquetado y G0 pasaron 50 de 50 verificaciones automáticas, incluidas pruebas de perturbación que alteran valores futuros; el cargador de ventanas pasó 73 de 73 y las definiciones de modelos 54 de 54 verificaciones frente a la especificación inicial.

Cuatro observaciones orientan el trabajo restante. Primero, las etiquetas proxy e inyectadas son casi disjuntas (Jaccard ≤ 0.0012), por lo que H3 no se cumple de forma trivial. Segundo, el Esquema A tiene una prevalencia menor al 0.3–2 % anticipado y solo 29.2 % de bloques con ambas clases, lo que limita la intersección de bloques sobre la que se calcula H3; además sus dos agregaciones discrepan para G0 (0.084 medio por bloque sobre 84 bloques evaluables, 0.003 agregado, unas tres veces la prevalencia agregada), por lo que cada PR-AUC se reporta con su agregación. Tercero, G0 está muy por encima del azar bajo inyección, en línea con la competitividad de los detectores simples [13], [17], pero depende mucho del tipo: separa casi perfectamente las anomalías puntuales y mal

las colectivas, que son tres cuartas partes de los instantes inyectados, por lo que cualquier ganancia de DL debe leerse por tipo. Cuarto, el costo de entrenamiento medido (4.3–5.4 min por época en CPU) obligó a la búsqueda reducida de la Sección III, solo parcialmente mitigada por el reentrenamiento con varias semillas.

V. Discusión y amenazas a la validez

La evidencia previa de que las líneas base estadísticas pueden rivalizar con DL [14], [17] motiva H1, pero no detectar una ventaja de DL se reportará con tamaños de efecto e incertidumbre, sin interpretar la no significancia como evidencia de equivalencia. La latencia publicada de SI-DMSeq (unos 55 ms por secuencia para 46 zonas y ventanas de 24 pasos [7]) corresponde a otra carga, por lo que todos los métodos se medirán bajo una misma configuración; el criterio de 10 ms (unos 3 s para una ventana por sensor, muy por debajo del intervalo de muestreo de 5 min) es un criterio técnico de este estudio.

Validez externa: un solo conjunto de datos, una red de autopistas y unos once días de prueba limitan la generalización; H1 concierne a anomalías inyectadas, no a incidentes verificados. *Validez de constructo:* ningún esquema representa incidentes verificados; las anomalías inyectadas difieren de las reales [20] y los eventos reales sin etiquetar actúan como pseudonegativos [21]. *Validez interna:* el Esquema A comparte familia de reglas con G0, de ahí su rol restringido; todo ajuste es local al pliegue. G0 usa solo flujo y una ventana de 22 pasos frente a 12 pasos y ocho canales de las redes, y la búsqueda reducida de una semilla puede favorecer arquitecturas que convergen temprano. Los controles de atajo se fijaron tras una pequeña corrida exploratoria. *Validez de conclusión:* los pliegues progresivos no son independientes y los sensores comparten dinámica, por lo que el análisis de Friedman en validación es exploratorio y se planea un análisis solo del pliegue 3 como chequeo de robustez. *Validez de la métrica:* el PR-AUC puntual da más peso a las anomalías largas (colectivas) y es sensible al desfase [16], [18]; se reportarán resultados por tipo. *Validez de implementación:* G7 corre en otro framework, un confusor declarado para la latencia; el hardware de entrenamiento y de latencia se documentará por separado.

VI. Conclusión

Especificamos y ejecutamos parcialmente un protocolo uniforme y reproducible para comparar detectores DL con una línea base no paramétrica sobre flujo de autopistas de PeMS-D4 bajo dos esquemas de etiquetado construidos por separado. Los resultados preliminares muestran que los esquemas producen conjuntos positivos en gran medida no solapados, que la línea base está muy por encima del azar bajo inyección pero depende del tipo de anomalía, y que el presupuesto nominal de ajuste era inviable, lo que llevó a una búsqueda reducida declarada. Siguen la batería DL, las pruebas de H1–H3, los controles de atajo y la medición de latencia; el código (licencia MIT), las configuraciones y las semillas se publicarán con los resultados.

Referencias

[1] C. Chen, "Freeway performance measurement system (PeMS)," Institute of Transportation Studies, University of California, Berkeley, Research Report UCB-ITS-PRR-2003-22, 2003, sponsored by the California Department of Transportation (Caltrans).

[2] Federal Highway Administration, Office of Operations, "Reducing non-recurring congestion," https://ops-dr.fhwa.dot.gov/program_areas/reduce-non-cong.htm, undated web page; accessed 27 Oct. 2026.

[3] CBS News San Francisco, "San Francisco has the 5th worst traffic congestion in the world, INRIX study finds," https://www.cbsnews.com/sanfrancisco/news/san-francisco-5th-worst-traffic-congestion-in-the-world-inrix-study/, news report on the INRIX 2017 global congestion ranking, 6 Feb. 2018; accessed 27 Oct. 2026.

[4] H. Zhang, S. Zhao, R. Liu, W. Wang, Y. Hong, and R. Hu, "Automatic traffic anomaly detection on the road network with spatial-temporal graph neural network representation learning," *Wireless Communications and Mobile Computing*, vol. 2022, p. 4222827, 2022.

[5] M. Méndez, A. Ibias, and M. Núñez, "Using deep learning to detect anomalies in traffic flow," in *Proc. 14th Asian Conf. on Intelligent Information and Database Systems (ACIIDS 2022)*, ser. Lecture Notes in Artificial Intelligence, vol. 13757. Springer, 2022, pp. 299–312.

[6] J. Ijaradar, S. Pape, C. Tan, M. Körner, and M. Wang, "Data-driven anomaly detection in urban traffic data: A deep learning approach," in *Proc. 9th Int. Conf. on Models and Technologies for Intelligent Transportation Systems (MT-ITS)*. IEEE, 2025.

[7] M. Nouri and M. Ilbeigi, "A self-imputing deep multitask sequence model for traffic disruption detection in extreme conditions," *IEEE Access*, vol. 13, pp. 165 873–165 886, 2025.

[8] A. Coursey, J. Ji, M. Quinones-Grueiro, W. Barbour, Y. Zhang, T. Derr, G. Biswas, and D. B. Work, "FT-AED: Benchmark dataset for early freeway traffic anomalous event detection," in *Advances in Neural Information Processing Systems (NeurIPS), Track on Datasets and Benchmarks*, vol. 37, 2024, pp. 15 526–15 548.

[9] Y. Sun, T. Mallick, P. Balaprakash, and J. Macfarlane, "A data-centric weak supervised learning for highway traffic incident detection," *Accident Analysis and Prevention*, vol. 176, p. 106779, 2022.

[10] H. Yang, C. Liao, Z. Dong, C. Chen, D. Mo, and W. Chen, "SUMO-enhanced traffic anomaly detection: enhancing spatiotemporal transferability through simulation-based data augmentation," *Digital Transportation and Safety*, vol. 4, no. 4, pp. 264–274, 2025.

[11] S. Kim, K. Choi, H.-S. Choi, B. Lee, and S. Yoon, "Towards a rigorous evaluation of time-series anomaly detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 36, no. 7, 2022, pp. 7194–7201.

[12] R. Wu and E. J. Keogh, "Current time series anomaly detection benchmarks are flawed and are creating the illusion of progress (extended abstract)," in *Proc. IEEE 38th Int. Conf. on Data Engineering (ICDE)*, 2022, pp. 1479–1480.

[13] S. Schmidl, P. Wenig, and T. Papenbrock, "Anomaly detection in time series: A comprehensive evaluation," *Proceedings of the VLDB Endowment*, vol. 15, no. 9, pp. 1779–1797, 2022.

[14] J. Audibert, P. Michiardi, F. Guyard, S. Marti, and M. A. Zuluaga, "Do deep neural networks contribute to multivariate time series anomaly detection?" *Pattern Recognition*, vol. 132, p. 108945, 2022.

[15] F. Rewicki, J. Denzler, and J. Niebling, "Is it worth it? comparing six deep and classical methods for unsupervised anomaly detection in time series," *Applied Sciences*, vol. 13, no. 3, p. 1778, 2023.

[16] Q. Liu and J. Paparrizos, "The elephant in the room: Towards a reliable time-series anomaly detection benchmark," in *Advances in Neural Information Processing Systems (NeurIPS), Track on Datasets and Benchmarks*, vol. 37, 2024, pp. 108 231–108 261.

[17] I. Taheri Sarteshnizi, M. Sarvi, S. Asadi Bagloee, and N. Nassir, "On the applicability of time series anomaly detection methods to real-world traffic volume data," *Transportation Research Part C: Emerging Technologies*, vol. 184, p. 105536, 2026.

[18] S. Sørbø and M. Ruocco, "Navigating the metric maze: a taxonomy of evaluation metrics for anomaly detection in time series," *Data Mining and Knowledge Discovery*, vol. 38, no. 3, pp. 1027–1068, 2024.

[19] K.-H. Lai, D. Zha, J. Xu, Y. Zhao, G. Wang, and X. Hu, "Revisiting time series outlier detection: Definitions and benchmarks," in *35th Conf. on Neural Information Processing Systems (NeurIPS 2021), Track on Datasets and Benchmarks*, 2021.

[20] C. U. Carmona, F.-X. Aubet, V. Flunkert, and J. Gasthaus, "Neural contextual anomaly detection for time series," in *Proc. 31st Int. Joint Conf. on Artificial Intelligence (IJCAI-22)*, 2022, pp. 2843–2851.

[21] M. Goswami, C. Challu, L. Callot, L. Minorics, and A. Kan, "Unsupervised model selection for time-series anomaly detection," in *Proc. 11th Int. Conf. on Learning Representations (ICLR)*, 2023.

[22] I. Taheri Sarteshnizi, S. Asadi Bagloee, M. Sarvi, and N. Nassir, "Traffic anomaly detection: Exploiting temporal positioning of flow-density samples," *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 5, pp. 4166–4180, 2024.

[23] S. Guo, Y. Lin, N. Feng, C. Song, and H. Wan, "Attention based spatial-temporal graph convolutional networks for traffic flow forecasting," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no. 01, 2019, pp. 922–929.

[24] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.